

Análise Avançada de Dados

Quais fatores mais influenciam o salário de um profissional de dados no Brasil em 2024?

Disciplina	Análise Avançada de Dados
Professora	Ma. Heloisa Guimarães
Instituição	Centro Universitário Santo Agostinho — UNIFSA
Base de Dados	State of Data Brazil 2024–2025 (Data Hackers / Bain & Company)
Fonte	kaggle.com/datasets/datahackers/state-of-data-brazil-20242025

1. Contexto

O mercado de dados brasileiro cresce aceleradamente, mas ainda carece de transparência salarial que oriente profissionais em início de carreira e empresas na precificação de talentos. A pergunta central deste trabalho — **quais fatores mais influenciam o salário de um profissional de dados no Brasil em 2024?** — nasce exatamente dessa lacuna.

A análise tem dois públicos principais. Para o **profissional de dados**, especialmente quem está iniciando a carreira ou planejando uma transição, os resultados oferecem referências concretas sobre quais competências e trajetórias estão associadas a salários mais altos. Para **empresas e recrutadores**, os achados ajudam a calibrar pacotes de remuneração e entender como variáveis como região, cargo e senioridade se relacionam com o mercado.

A relevância da pergunta vai além do interesse individual: desigualdades salariais por gênero e raça, quando documentadas com dados, tornam-se ponto de partida para políticas mais justas de contratação e promoção.

2. Sobre os Dados

A base utilizada é o **State of Data Brazil 2024–2025**, o maior mapeamento do mercado de trabalho em dados e inteligência artificial do Brasil, conduzido pela comunidade *Data Hackers* em parceria com a *Bain & Company*. A pesquisa contou com **5.217 respondentes** e mais de 400 colunas sobre perfil pessoal, cargo, salário, formação, ferramentas e satisfação profissional. A coleta ocorreu ao longo de 2024.

2.1 Perfil dos respondentes

A amostra é composta majoritariamente por profissionais empregados na área de dados, com concentração na região Sudeste. A participação é voluntária e, portanto, não representa uma

amostra aleatória do mercado — profissionais engajados em comunidades digitais tendem a estar super-representados.

2.2 Problemas de qualidade e decisões de limpeza

- **Faixas salariais em texto:** A coluna de salário não era numérica (ex.: "de R\$ 8.001/mês a R\$ 12.000/mês"). Convertemos para o **ponto médio aritmético** de cada faixa usando expressão regular. Para a faixa aberta inferior usamos R\$ 750; para a superior, R\$ 45.000. Essa decisão introduz imprecisão — toda análise numérica de salário deve ser lida com essa ressalva.
- **Nomes de colunas crípticos:** Prefixos como P1_a, P2_b_1 foram substituídos por nomes legíveis (ex.: faixa_salarial, senioridade, genero) usando o dicionário de dados oficial do Kaggle. Foram renomeadas 21 colunas-chave.
- **Missings em dados sensíveis:** Os campos genero e raca_etnia incluem a opção "Prefiro não informar", que não é erro de coleta — é escolha deliberada do respondente. Decidimos **não imputar** esses campos. Análises de salário por gênero e raça representam apenas quem optou por informar.
- **Missings em cargo e senioridade:** Aproximadamente 26,8% dos registros não tinham cargo ou senioridade preenchidos, correspondendo majoritariamente a estudantes e desempregados. Para a análise salarial, filtramos apenas profissionais com cargo, salário e senioridade informados, reduzindo a base para análise.
- **Inconsistência de cargo/título:** Títulos como "Analista de Dados/Data Analyst" foram agrupados em categorias simplificadas (Analista de Dados, Cientista de Dados, Engenheiro de Dados, etc.) para viabilizar comparações visuais claras.

Nota: cada decisão foi justificada em célula Markdown no notebook, com as respectivas implicações para a interpretação dos resultados.

3. Achados Principais

3.1 Distribuição salarial: assimétrica e concentrada

A distribuição dos salários é **assimétrica à direita** (assimetria positiva), o que significa que a maioria dos profissionais ganha abaixo da média. Por isso, a **mediana** é a medida mais representativa do salário típico no setor: ela não é inflacionada pelos salários elevados de uma minoria.

A amplitude salarial é expressiva — de menos de R\$ 1.000 a mais de R\$ 40.000 mensais — o que reforça a importância de analisar os *fatores* que explicam essa dispersão, e não apenas a média agregada do setor.

3.2 Senioridade: o fator com maior impacto individual

A análise bivariada mostrou **correlação forte e positiva** entre senioridade e salário (Spearman ρ elevado, $p < 0,001$). A progressão de Júnior para Sênior representa a maior alavanca salarial identificada na base — independentemente do cargo.

Em termos práticos, um profissional Sênior tende a receber medianas salariais significativamente superiores às de Plenos e Juniores no mesmo tipo de função. Isso indica que **acumular experiência e assumir responsabilidades mais complexas** é a estratégia mais direta para crescimento salarial no setor de dados.

3.3 Tipo de cargo: especialização técnica vale mais

Analisando as medianas salariais por cargo, observamos que **ML/AI Engineers e Engenheiros de Dados** consistentemente apresentam medianas mais altas do que Analistas de Dados e Analistas de BI, mesmo quando comparados no mesmo nível de senioridade. Analytics Engineers e Cientistas de Dados ocupam posições intermediárias.

Esse achado sugere que a especialização em áreas técnicas de alto valor — como arquitetura de dados, machine learning e inteligência artificial — está associada a uma remuneração premium no mercado brasileiro em 2024.

3.4 Experiência em anos: crescimento progressivo e consistente

A correlação de Spearman entre tempo de experiência em dados e salário é estatisticamente significativa ($p < 0,001$). A mediana salarial cresce de forma progressiva conforme os anos de experiência aumentam, com salto mais expressivo a partir de 5 anos de atuação na área.

Esse padrão reforça que a **senioridade formal** (Júnior/Pleno/Sênior) e o **tempo real de experiência** são dimensões complementares e ambas relevantes para a remuneração — profissionais com muitos anos de mercado mas título Pleno podem estar sendo subvalorizados.

3.5 Região: concentração no Sudeste, mas diferenças existem

O teste de Kruskal-Wallis confirmou diferenças estatisticamente significativas nas medianas salariais entre regiões. A região **Sudeste** apresenta as medianas mais altas, o que é esperado dado que São Paulo e Rio de Janeiro concentram a maior parte das empresas de tecnologia e centros de decisão corporativa do país.

Contudo, vale destacar que o trabalho remoto — amplamente adotado no setor de dados — pode estar suavizando essas diferenças ao longo do tempo, permitindo que profissionais de outras regiões acessem vagas com remuneração de grandes centros.

3.6 Gênero: desigualdade persiste mesmo controlando senioridade

A análise revelou diferença nas medianas salariais entre homens e mulheres. O dado mais relevante é que **essa diferença persiste mesmo quando comparamos profissionais do mesmo nível de senioridade** — o que indica que a desigualdade não é apenas um reflexo de mulheres estarem em proporção maior em cargos Júnior.

Isso aponta para uma diferença estrutural que vai além da experiência acumulada. É necessário cautela ao interpretar: a amostra exclui quem preferiu não informar o gênero, e a pesquisa voluntária pode ter viés de seleção. Ainda assim, o padrão é consistente com dados de outras pesquisas nacionais e internacionais sobre o setor.

4. Resposta à Pergunta Central

Com base nos achados da análise estatística, os fatores que mais influenciam o salário de um profissional de dados no Brasil em 2024 são, em ordem de impacto:

- **Senioridade** — É o preditor individual mais forte. A progressão de Júnior para Sênior está associada à maior diferença salarial observada, em todos os cargos analisados. Correlação de Spearman com o salário é forte e altamente significativa.
- **Tipo de cargo / especialização técnica** — ML/AI Engineers e Engenheiros de Dados têm medianas consistentemente superiores a Analistas de Dados e BI, mesmo no mesmo nível de senioridade. A especialização em dados e IA paga prêmio.
- **Tempo de experiência em dados** — Correlação positiva e significativa com o salário. Profissionais com mais de 5 anos na área registram saltos expressivos na remuneração mediana.
- **Região** — O Sudeste concentra as maiores medianas salariais, com diferenças estatisticamente significativas em relação a outras regiões do país.
- **Gênero** — A diferença salarial entre homens e mulheres é observável e persiste mesmo controlada pela senioridade, sugerindo componente estrutural além da distribuição de cargos.

Em síntese: um profissional de dados que maximiza salário em 2024 tende a ser Sênior, especializado em Engenharia de Dados ou ML/AI, com mais de 5 anos de experiência, atuando no Sudeste. A combinação dessas variáveis explica a maior parte da variância salarial observada na base.

5. Limitações e Ética

5.1 O que a análise não consegue responder

Os dados são de pesquisa voluntária, o que significa que o perfil dos respondentes não é necessariamente representativo de todo o mercado de dados brasileiro. Profissionais menos conectados a comunidades digitais — especialmente fora do Sudeste e do Sul — estão sub-representados.

Os salários são estimativas de ponto médio de faixas, não valores exatos. Isso introduz imprecisão sistemática em todas as métricas calculadas. A análise identifica associações, não causalidade: dizer que senioridade *causa* salário mais alto requer um desenho experimental que a pesquisa não permite.

Variáveis potencialmente importantes — como o porte da empresa, o setor de atuação e a formação específica — foram analisadas de forma superficial ou deixadas para trabalhos futuros devido ao escopo desta análise.

5.2 Vieses nos dados

A pesquisa tem **viés de auto-seleção**: quem responde voluntariamente tende a ser mais engajado com o mercado e possivelmente mais bem remunerado. Isso pode inflar as medianas salariais observadas em relação ao mercado real.

Os campos de gênero e raça/etnia têm taxas relevantes de não-resposta. Análises baseadas nesses campos representam apenas quem optou por informar, o que pode introduzir viés de seleção adicional nos resultados sobre desigualdade salarial.

5.3 Cuidados éticos na comunicação de diferenças salariais

Ao reportar diferenças salariais por gênero e raça, é necessário adotar postura responsável. Dados sobre desigualdade podem ser mal interpretados se apresentados sem contexto — por exemplo, atribuindo diferenças a fatores individuais quando evidências apontam para barreiras estruturais.

Recomendamos que os achados sobre gênero e raça sejam sempre acompanhados de informações sobre o tamanho da amostra em cada grupo, a metodologia de controle pela senioridade, e as limitações dos dados de não-resposta. A análise deve informar políticas de equidade, não naturalizá-las como inevitáveis.

Fonte: State of Data Brazil 2024–2025 — Data Hackers / Bain & Company. Análise realizada com Python (pandas, numpy, matplotlib, seaborn, scipy). Disciplina: Análise Avançada de Dados — UNIFSA, 2025.